DOCUMENTO DE REQUERIMIENTOS

Proceso de Ordenamiento - (Scoring de Contactabilidad)

1. Objetivo

Definir los requerimientos funcionales y técnicos para la implementación del proceso de Ordenamiento (Scoring de Contactabilidad) de Reconocer Máster en la plataforma Amazon Redshift, garantizando equivalencia funcional completa con el proceso existente en Teradata.

El proceso de Ordenamiento calcula un score de probabilidad de contacto para cada dato de contacto de una persona y genera un ranking (orden_prioridad) que indica cuál intentar primero para optimizar la contactabilidad, priorizando el canal y dato con mayor probabilidad de éxito.

2. Alcance

Una persona en el sistema puede tener múltiples datos de contacto (direcciones físicas, teléfonos fijos, celulares y correos electrónicos) reportados por distintos suscriptores, sin un criterio objetivo de cuál intentar primero para lograr contacto efectivo.

El sistema calcula un score de probabilidad de contacto y genera un ranking por persona y canal para los 4 tipos de ubicación: Dirección (DIR), Teléfono Fijo (TEL), Celular (CEL) y Email (EMA). El algoritmo no compara canales entre sí; cada canal se procesa y rankea de forma independiente.

El resultado funcional es un orden ascendente por persona y canal, donde el valor 1 representa el dato con mayor prioridad relativa.

Incluido en alcance:

- Fases funcionales de Materialización, Atributos de Cuenta, Ubicaciones y Scoring.
- Reglas de elegibilidad para datos que pueden participar del Ordenamiento.
- Definición de características, categorización, Betas, score y ranking por canal.
- Persistencia de orden_prioridad y controles de idempotencia.
- Controles de paridad funcional Teradata vs Redshift.

Fuera de alcance:

- DDL, SQL, procedimientos almacenados, notebooks o código específico de implementación.
- Diseño físico de Redshift: sort keys, distribution style, compresión, tuning o costos.
- Herramienta específica de orquestación, despliegue o monitoreo técnico.
- Incorporación de nuevas fuentes o características que no hagan parte del baseline aprobado.

3. Requerimientos Funcionales

Los requerimientos funcionales se organizan por las cuatro fases del proceso de Ordenamiento. Las fases se ejecutan siempre en secuencia obligatoria: Fase 1 → Fase 2 → Fase 3 → Fase 4.

3.1 Fase 1 — Materialización (Identificación de personas con cambios)

Identifica qué personas tuvieron cambios en sus datos desde la última ejecución de Ordenamiento. Solo esas personas se re-procesan (no las 65–70 millones cada vez).

ID	Requerimiento	Prioridad
F1-01	El sistema debe identificar qué personas tuvieron lotes nuevos en el modelo BTT (cuentas, comportamiento crediticio) desde la última ejecución.	**Alta**
F1-02	El sistema debe identificar qué personas tuvieron lotes nuevos en el modelo REC (ubicaciones, bloqueos, unificación) desde la última ejecución.	**Alta**
F1-03	La unificación de ambos modelos (BTT + REC) no debe generar duplicados: cada combinación persona-buró debe ser única en unifica_btt_reconocer.	**Alta**
F1-04	Si no hay lotes nuevos en ningún modelo, la tabla de trabajo debe quedar vacía y no se ejecuta reproceso.	**Alta**
F1-05	Al finalizar, las 14 tablas intermedias de paso deben eliminarse automáticamente.	**Alta**
F1-06	Se debe registrar inicio y fin de la fase en el log de ejecución con timestamp.	**Alta**
F1-07	El universo a ordenar se establece por fecha paramétrica al proceso o por la fecha de último ordenamiento almacenada en tabla de control.	**Media**
F1-08	Los cambios identificados incluyen: carga/actualización de ubicaciones, estandarización de direcciones, unificación de direcciones, bloqueos de direcciones, registros nuevos en cuentas y cambios en comportamientos o endeudamiento.	**Alta**

3.2 Fase 2 — Atributos de Cuenta (Clasificación y Hash)

Extrae las cuentas de las personas afectadas, calcula una ventana temporal de 12 meses, clasifica cada cuenta en un Portafolio y genera un hash MD5 para detectar cambios entre ejecuciones.

ID	Requerimiento	Prioridad
F2-01	Solo se deben extraer cuentas de personas identificadas en la Fase 1 (materialización).	**Alta**
F2-02	Se debe calcular una ventana temporal de 12 meses hacia atrás desde la fecha de novedad.	**Alta**
F2-03	Se debe extraer el comportamiento activo dentro de esa ventana.	**Alta**
F2-04	Se debe extraer el comportamiento pasivo dentro de esa ventana.	**Alta**
F2-05	Cada cuenta se debe clasificar en uno de 9 portafolios: CO, RO, VE, HP, IN, OT, CC, AH, CT. No puede haber valores fuera de este catálogo.	**Alta**
F2-06	No puede haber portafolios vacíos (NULL).	**Alta**
F2-07	Se debe generar un hash MD5 de exactamente 32 caracteres por cada registro para detectar cambios entre ejecuciones.	**Alta**

F2-08	El campo concatena no puede ser vacío ni NULL.	**Alta**
F2-09	Se debe registrar inicio y fin de la fase en el log de ejecución.	**Alta**
F2-10	Se generan 3 fechas de insumo por cada Persona – Cuenta – Suscriptor para el cálculo de número de meses de reporte.	**Alta**

3.3 Fase 3 — Ubicaciones (Vector de Dirección y Persistencia por Hash)

Prepara los datos de ubicación de cada persona, enriquece con datos de estandarización y tipo de persona/cuenta, calcula un hash MD5 y persiste solo cambios (nuevos o modificados) en la tabla definitiva.

ID	Requerimiento	Prioridad
F3-01	Se deben excluir automáticamente los registros bloqueados.	**Alta**
F3-02	Se deben excluir los registros unificados (hijos). Solo se procesan direcciones vigentes (ind_unificacion IS NULL).	**Alta**
F3-03	Tipo persona se debe clasificar correctamente (no puede haber tipo_persona NULL).	**Alta**
F3-04	Se debe generar un hash MD5 de 32 caracteres por cada dirección.	**Alta**
F3-05	Los registros nuevos se deben insertar en ubicacion_atributo_hash.	**Alta**
F3-06	Los registros modificados (donde el hash difiere) se deben actualizar. Los registros sin cambios no se tocan.	**Alta**
F3-07	La llave de detección de cambios es: cod_pin_persona + id_buro_persona + cod_dw_persona_ubic.	**Alta**
F3-08	Se debe registrar inicio y fin de la fase en el log de ejecución.	**Alta**
F3-09	Solo se ordenan ubicaciones con cuentas activas para la fuente ICBDIR (Suscriptor). Para otras fuentes no se asocian cuentas a las personas y sus ubicaciones.	**Alta**
F3-10	No se ordenan ubicaciones que no sean válidas (resultado de algoritmo de estandarización).	**Alta**
F3-11	No se ordenan ubicaciones que hayan sido unificadas (resultado del algoritmo de unificación).	**Alta**

3.4 Fase 4 — Scoring (4 Canales)

Calcula un score de contactabilidad por canal usando regresión logística: Score = Σ (categoría / max_categoría) × Beta. Cada dato de contacto se rankea dentro de su canal para la persona.

3.4.1 Requerimientos Generales de Scoring

ID	Requerimiento	Prioridad
F4-01	El score se debe calcular para 4 canales: Dirección (DIR), Teléfono Fijo (TEL), Celular (CEL) y Email (EMA).	**Alta**
F4-02	La fórmula es: (categoría / max_categoría) × Beta por cada característica del canal.	**Alta**
F4-03	Los coeficientes Beta se deben leer siempre de la tabla beta_ordenamiento, nunca hardcodeados en el código.	**Alta**

F4-04	El ranking (lugar) se calcula como ROW_NUMBER ordenado por score descendente, agrupado por persona dentro de cada canal.	**Alta**
F4-05	El score no puede ser NULL para ningún dato vigente.	**Alta**
F4-06	El valor orden_prioridad resultante se debe escribir en la tabla relacion_persona_ubicacion.	**Alta**
F4-07	Solo los datos vigentes (no hijos de Unificación) reciben score.	**Alta**
F4-08	El proceso es idempotente: ejecutar 2 veces consecutivas produce el mismo resultado sin duplicar registros.	**Alta**
F4-09	Los Betas deben permanecer parametrizados y versionables; no deben quedar embebidos en la lógica de scoring.	**Alta**

3.4.2 Canal DIR (Dirección) — 12 características

ID	Requerimiento	Prioridad
F4-DIR-01	Se deben calcular 12 características: DIR001IN, DIR004RO, DIR007TO, DIR010FI, DIR013OT, DIR017, DIR019, DIR034FI, DIR050TO, DIR057, DIR059, DIR009.	**Alta**
F4-DIR-02	DIR001IN = meses desde primer reporte de la dirección.	**Alta**
F4-DIR-03	DIR009 = entidades distintas reportando la dirección.	**Alta**
F4-DIR-04	DIR017 = tipo ubicación (RES=1, LAB=2, CRR=3).	**Alta**
F4-DIR-05	La categorización debe usar los rangos/umbrales definidos en el modelo de scoring vigente.	**Alta**
F4-DIR-06	Los Betas utilizados deben tener prefijo CO00DIR o CO01DIR.	**Alta**

3.4.3 Canal TEL (Teléfono Fijo) — 11 características

ID	Requerimiento	Prioridad
F4-TEL-01	Se deben calcular 11 características: TEL001 a TEL025.	**Alta**
F4-TEL-02	TEL010 = porcentaje de reportes con coincidencia geográfica.	**Alta**
F4-TEL-03	TEL020 = indicador binario de coincidencia geográfica (1 si no tiene, 4 si tiene).	**Alta**
F4-TEL-04	Solo se deben considerar reportes válidos (se excluyen los marcados como NO VALIDA).	**Alta**
F4-TEL-05	Los Betas utilizados deben tener prefijo CO01TEL.	**Alta**

3.4.4 Canal CEL (Celular) — 11 características

ID	Requerimiento	Prioridad
F4-CEL-01	Se deben calcular 11 características: CEL003 a CEL023.	**Alta**
F4-CEL-02	CEL013 = operador principal identificado por prefijos (310–314).	**Alta**
F4-CEL-03	CEL014 = indicador de si la persona tiene cuenta POSPAGO.	**Alta**
F4-CEL-04	CEL018 = valor del operador según tabla de mapeo V_Operador_Ord_Cel.	**Alta**
F4-CEL-05	Los Betas utilizados deben tener prefijo CO01CEL.	**Alta**

F4-CEL-06	Cuando el operador no se encuentra en la tabla de mapeo, se debe asignar un valor por defecto definido funcionalmente (operador no mapeado).	**Alta**

3.4.5 Canal EMA (Email) — 13 características

ID	Requerimiento	Prioridad
F4-EMA-01	Se deben calcular 13 características: EMA003 a EMA025.	**Alta**
F4-EMA-02	EMA014 = indicador de dominio conocido (gmail, hotmail, yahoo, outlook).	**Alta**
F4-EMA-03	EMA025 = ratio de recencia calculado como (min_meses / max_meses × 100).	**Alta**
F4-EMA-04	Los Betas utilizados deben tener prefijo CO01EMA.	**Alta**

3.5 Reglas Generales — Comportamiento Transversal

ID	Requerimiento	Prioridad
RG-01	Las fases se ejecutan siempre en secuencia: F1 → F2 → F3 → F4 (hay dependencia de tablas intermedias).	**Alta**
RG-02	Los coeficientes Beta deben coincidir exactamente con los valores vigentes en la tabla beta_ordenamiento.	**Alta**
RG-03	El proceso es idempotente: 2 ejecuciones consecutivas producen exactamente el mismo resultado.	**Alta**
RG-04	Las cuentas bloqueadas se excluyen del cálculo de atributos.	**Alta**
RG-05	Solo direcciones vigentes (no hijas) reciben score.	**Alta**
RG-06	El hash MD5 debe producir una salida consistente y determinística para los mismos datos de entrada.	**Alta**
RG-07	Todos los esquemas son fijos (rec_stage, rec_datos). No se utiliza SQL dinámico.	**Alta**
RG-08	Cada fase registra inicio y fin con timestamp en la tabla de log de ejecución.	**Alta**
RG-09	Para un mismo corte funcional, Redshift debe reproducir el resultado Teradata o explicar una diferencia aprobada.	**Alta**
RG-10	No se debe aprovechar el cambio de plataforma para modificar umbrales, redefinir características, alterar Betas, introducir nuevas señales o cambiar exclusiones sin decisión funcional explícita.	**Alta**

4. Requerimientos de Gobernanza de Migración

La migración debe preservar el resultado de negocio del algoritmo. Si el requerimiento resumido, la documentación histórica y el comportamiento ejecutable de Teradata no coinciden, la diferencia no debe resolverse de forma implícita: debe clasificarse, decidirse y aprobarse antes de certificar Redshift.

ID	Requerimiento	Prioridad

G-01	Toda diferencia entre el comportamiento Teradata y la construcción Redshift debe clasificarse como: (a) Paridad de migración, (b) Cambio funcional aprobado, o (c) Asunto técnico pendiente de validación.	**Alta**
G-02	Las diferencias clasificadas como cambio funcional requieren aprobación explícita del área funcional antes de certificación.	**Alta**
G-03	Se debe mantener una bitácora de diferencias que registre: tipo de diferencia, descripción, decisión tomada, fecha y responsable.	**Alta**
G-04	Si se cambia el algoritmo durante la migración, la iniciativa deja de ser solo migración y pasa a ser migración más evolución funcional, requiriendo aprobación adicional.	**Alta**
G-05	La validación principal debe comparar resultados funcionales para un mismo corte de datos y mismos parámetros.	**Alta**
G-06	Los Betas deben poder versionarse y auditarse: cada ejecución debe registrar qué versión de Betas utilizó.	**Media**

5. Criterios de Aceptación

5.1 Criterios Funcionales

ID	Requerimiento	Prioridad
CA-F01	Cada dato de contacto vigente tiene un orden_prioridad calculado dentro de su canal.	**Alta**
CA-F02	Los datos marcados como hijos en Unificación (ind_unificacion = 1) NO reciben score ni ranking.	**Alta**
CA-F03	El score se calcula estrictamente con la fórmula de regresión logística usando los Betas vigentes de beta_ordenamiento.	**Alta**
CA-F04	0 scores duplicados para el mismo dato de contacto en el mismo canal (garantía de idempotencia).	**Alta**
CA-F05	Los coeficientes Beta utilizados coinciden exactamente con los valores vigentes en beta_ordenamiento.	**Alta**
CA-F06	El ranking refleja correctamente la prioridad: valor 1 = mayor probabilidad relativa de contacto.	**Alta**

5.2 Criterios de Migración

ID	Requerimiento	Prioridad
CA-M01	Para el mismo corte funcional y mismos parámetros, Redshift debe reproducir el resultado de Teradata.	**Alta**
CA-M02	Toda diferencia detectada debe estar documentada en la bitácora de diferencias con su clasificación y aprobación.	**Alta**
CA-M03	No se introducen cambios funcionales implícitos durante la migración.	**Alta**
CA-M04	Las cuatro fases conservan su dependencia funcional: Fase 1 → Fase 2 → Fase 3 → Fase 4.	**Alta**

5.3 Criterios Técnicos

ID	Requerimiento	Prioridad
CA-T01	El hash MD5 produce una salida consistente y determinística de 32 caracteres.	**Alta**
CA-T02	Cada fase registra inicio y fin con timestamp en el log de ejecución.	**Alta**
CA-T03	Las tablas intermedias se eliminan al finalizar cada fase.	**Alta**
CA-T04	Los esquemas son fijos (rec_stage, rec_datos). No se utiliza SQL dinámico.	**Alta**
CA-T05	El proceso soporta ejecución incremental (solo personas con cambios) y no requiere reprocesar todo el universo.	**Alta**

6. Supuestos y Restricciones

Precondiciones:

- Solo se procesan datos de contacto con estado no bloqueado y no unificado previamente (ind_unificacion IS NULL).
- El proceso de Unificación de Direcciones Físicas debe haberse ejecutado antes del Ordenamiento.
- La tabla de coeficientes Beta (beta_ordenamiento) debe estar poblada con los valores vigentes.
- Las fases se ejecutan en secuencia obligatoria: Fase 1 → Fase 2 → Fase 3 → Fase 4.

Supuestos:

- La información de Reconocer Máster y BDM está disponible y actualizada al momento de la ejecución.
- El modelo estadístico (Betas, umbrales, características) no cambia durante el proceso de migración salvo aprobación explícita.
- Los procesos de Estandarización y Unificación previos han ejecutado correctamente.
- El score funciona como priorización relativa, no como probabilidad calibrada, mientras no exista una transformación explícita definida.

Restricciones:

- No se deben modificar umbrales, redefinir características, alterar Betas ni introducir nuevas señales sin decisión funcional explícita.
- El proceso no compara canales entre sí; cada canal se procesa de forma independiente.
- El universo se limita a personas con cambios desde la última ejecución; no se reprocesa la totalidad.
- La migración debe separar claramente paridad funcional de evolución funcional.

7. Glosario

Término	Definición
Persona a recalcular	Persona identificada con cambios en información de ubicaciones, cuentas, comportamiento, bloqueos, estandarización o unificación desde el último Ordenamiento.
Dato de contacto vigente	Ubicación o dato de contacto que puede participar porque está activo para el proceso, no está bloqueado, no es hijo de unificación y cumple reglas de validez aplicables.
Característica	Variable funcional calculada a partir de historia de reportes, cuentas, recencia, fuente, operador, contactabilidad u otra evidencia usada por el modelo.
Categoría	Transformación discreta del valor de una característica según rangos/umbrales del modelo.
Beta / peso	Coeficiente parametrizado que define la contribución relativa de una característica al score.
Score	Suma de las contribuciones de las características aplicables a un dato de contacto. Se usa para ordenar; no debe asumirse como probabilidad calibrada.
Orden Prioridad (Lugar)	Posición del dato dentro de la persona y el canal, ordenada de mayor score a menor score. 1 es la mayor prioridad.
Hash funcional (MD5)	Huella determinística de 32 caracteres utilizada para detectar cambios y evitar reprocesar registros sin modificación.
Idempotencia	Propiedad por la cual dos ejecuciones consecutivas con los mismos datos producen el mismo estado funcional sin duplicados.
Portafolio	Clasificación de una cuenta en una de 9 categorías: CO, RO, VE, HP, IN, OT, CC, AH, CT.
Materialización	Fase 1 del proceso que identifica personas con cambios y construye el universo a recalcular.
BTT	Modelo de datos que contiene información de cuentas y comportamiento crediticio.
REC (Reconocer)	Modelo de datos que contiene información de ubicaciones, bloqueos y unificación.
BDM	Business Data Model — modelo de datos del buró que incluye personas, cuentas, saldos y comportamientos.